Chain Of Thought (CoT)

SOTA2 - Group C

Anton Kesy, Étienne Muser, Katharina Schindler, Lukas Fehrenbacher, Nico Ruschmann

Offenburg University of Applied Sciences

WS 2024/2025

Was ist Chain-of-Thought (CoT) Prompting?

- Entwickelt von Google Research (2022)
- Eine Methode, die KI-Modelle zur **schrittweisen Darlegung** ihrer Denkprozesse anleitet
- Verbessert die Qualität und Nachvollziehbarkeit von KI-Antworten
- **Funktionsweise:** CoT erweitert den In-Context-Learning (ICL) Ansatz, indem jedes Demonstrationspaar (Eingabe, Ausgabe) um eine Gedankenkette erweitert wird: (Eingabe, Gedankenkette, Ausgabe). Die Gedankenkette besteht aus einer Reihe von Zwischenschritten des Denkens, die die Eingabe mit der Ausgabe verbinden.

Traditionelles vs. CoT Prompting

Traditionell:

```
Frage: "Was ist 13 x 27?"
Antwort: "351"
```

Chain-of-Thought:

```
Frage: "Was ist 13 x 27?"
Antwort:
1. 13 x 20 = 260
2. 13 x 7 = 91
3. 260 + 91 = 351
```

Traditionelles vs. CoT Prompting

Traditionell:

```
Frage: "Hat ein Geschäft mit 150€ Einnahmen und
180€ Ausgaben Gewinn gemacht?"
Antwort: "Nein"
```

Chain-of-Thought:

```
Frage: "Hat ein Geschäft mit 150€ Einnahmen und
180€ Ausgaben Gewinn gemacht?"
Antwort:
1. Einnahmen: 150€
2. Ausgaben: 180€
3. Differenz: 150€ - 180€ = -30€
4. Ein negativer Wert bedeutet Verlust
5. Ergebnis: Nein, Verlust von 30€
```

Vorteile von CoT

1. **Erhöhte Genauigkeit**
   - Strukturiertes Denken reduziert Fehler
   - Schrittweise Überprüfung möglich
2. **Bessere Nachvollziehbarkeit**
   - Transparenter Gedankengang
   - Vereinfachte Fehleranalyse
3. **Lerneffekt**
   - Menschen können von der Methodik lernen
   - Verbessertes Verständnis komplexer Probleme

Hauptanwendungsgebiete

- Mathematische Berechnungen
- Logische Schlussfolgerungen
- Komplexe Entscheidungsprozesse
- Textaufgaben
- Argumentationsanalysen

Grenzen und Herausforderungen

1. **Komplexität der Antworten**
   - Längere Antwortzeiten
   - Höherer Token-Verbrauch
   - Mehr Kontext erforderlich
2. **Qualität der Zwischenschritte**
   - Nicht alle Schritte sind immer relevant
   - Risiko von Überexplikation
   - Mögliche Fehlerfortpflanzung in den Zwischenschritten
3. **Anwendungsspezifische Limitationen**
   - Nicht für alle Aufgabentypen gleich gut geeignet
   - Bei einfachen Fragen möglicherweise überdimensioniert
   - Erfordert sorgfältige Prompt-Gestaltung

Vergleich: CoT-Prompting im Bereich des arithmetischen Denkens

Experimentelles Setup: Anwendung von Chain-of-Thought-Prompting auf verschiedene Sprachmodelle und Benchmarks für mathematische Textaufgaben.

- **Benchmarks:** fünf Datensätze für mathematische Textaufgaben: GSM8K, SVAMP, ASDiv, AQuA und MAWPS.
- **Standard-Prompting:** Standard-Few-Shot-Prompting
- **Chain-of-Thought-Prompting:** Erweiterung um eine Folge von Schritten (Chain of Thought), die zur Lösung führen
- **Sprachmodelle:** Es wurden fünf große Sprachmodelle evaluiert: GPT-3, LaMDA, PaLM, UL2 20B und Codex

Vergleich: CoT-Prompting im Bereich des arithmetischen Denkens

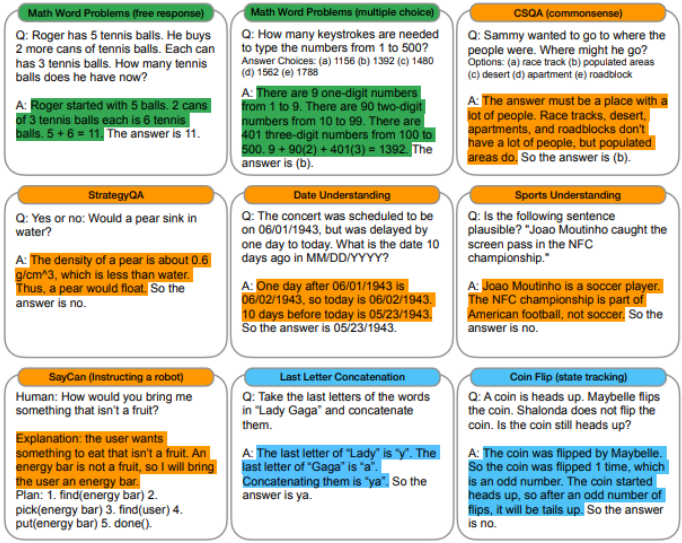

Vergleich: CoT-Prompting im Bereich des arithmetischen Denkens

Ergebnisse:

- **Emergente Fähigkeit:**
  - Chain-of-Thought-Prompting ist eine emergente Fähigkeit von Sprachmodellen, die erst bei Modellen mit etwa 100 Milliarden Parametern auftritt.
  - Kleinere Modelle erzeugen zwar flüssige, aber unlogische Gedankengänge, was zu schlechteren Ergebnissen führt.
- **Komplexitätssteigerung:**
  - Chain-of-Thought-Prompting erzielt größere Leistungsgewinne bei komplexeren Problemen.
  - Bei einfacheren Datensätzen waren die Verbesserungen geringer oder negativ.

Vergleich: CoT-Prompting im Bereich des arithmetischen Denkens

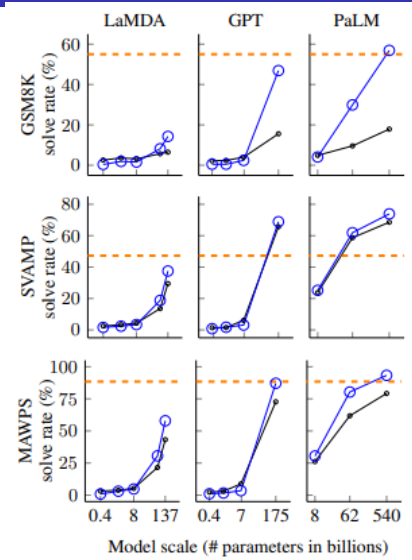

Standard prompting
Chain-of-thought prompting
Prior supervised best

Eine Einführung in XoT

- neuartiger Ansatz zur Gedankenfindung für große LLMs
- Grenzen des *Penrose-Dreiecks* (bestehende Paradigmen der Gedankenfindung einschränkt) überwinden

- Leistung
  - übertrifft bestehende Ansätze in Bezug auf die Genauigkeit bei verschiedenen Problemlösungsaufgaben (Game 24, 8-Puzzle, Pocket Cube)
- Effizienz
  - minimiert die Anzahl der LLM-Aufrufe durch Reinforcement Learning und Monte Carlo Tree Search (MCTS)
- Flexibilität
  - ermöglicht unterschiedliche Gedankenstrukturen die den menschlichen Mindmapping-Prozessen ähneln (Graphen)
  - unterschiedliche und kreative Denkprozesse zu entwickeln, insbesondere bei Problemen mit mehreren Lösungen

Vergleich mit anderen Prompting Ansätzen

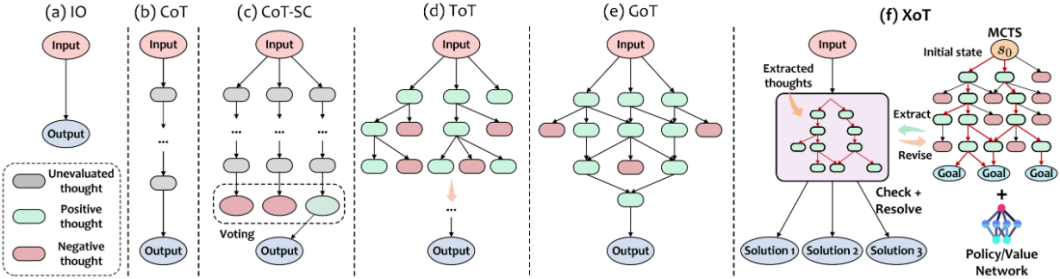

Paradigm	Performance	Efficiency	Flexibility
IO	✗	✓	✗
CoT	✗	✓	✗
CoT-SC	✗	✗	✗
ToT	✓	✗	✗
GoT	✓	✗	✓
XoT	✓	✓	✓

- IO (Input-Output)
- CoT (Chain of Thought)
- CoT-SC (CoT with Self-Consistency)
- ToT (Tree of Thoughts)
- GoT (Graph of Thoughts)
- XOT (Everything of Thoughts)

XoT Hauptkomponenten:

1. MCTS-Modul, das von Policy-/Value-Netzwerken gesteuert wird
   - wird vorab auf bestimmte Aufgaben trainiert, um die Gedankensuche zu optimieren
   - integriert externes Domänenwissen und Planungsfähigkeiten in die von den LLMs verwendeten "Gedanken"
2. LLM-Solver für Gedankenrevision und Inferenz
   - verwendet vom MCTS-Modul generierten *Gedanken*, um das Problem zu lösen
   - Solver kann *Gedanken* mithilfe der internen Kenntnisse des LLM überarbeiten
     - Zuverlässigkeit der Antwort verbessern

Thoughts searching with MCTS

- Mehrere “Simulationen”
- 3 Stufen

1. Selection
2. Evaluation and expansion
3. Backpropagation

- Policy and Value network training

Thought inference with MCTS

- Mehrere Simulationen mit MCTS durchführen
- Single solution: State mit höchstem visit count
- Multiple solutions: M Pfade wählen
- Thoughts werden concateniert
- LLM kann Feedback zu fehlerbehafteten Zuständen geben -> Zyklus

Ergebnisse Game of 24 (1/2)

- XOT übertrifft alle anderen getesteten Methoden in Bezug auf die Genauigkeit im Spiel 24. Die **Genauigkeit** von XOT mit **einer Revision** liegt bei **79,56 %** mit GPT-3.5 und 74,45 % mit GPT-4. Nach **drei Revisionen** steigt diese auf **90,51%** bzw. **85,40%**.
- XOT benötigt deutlich **weniger LLM-Aufrufe** als andere Methoden, die eine vergleichbare Genauigkeit erreichen. Während ToT (b=3) mit GPT-4 eine Genauigkeit von 60,58 % erreicht, benötigt es dafür fast 40 LLM-Aufrufe. XOT hingegen benötigt weniger als 2 LLM-Aufrufe, selbst mit drei Revisionen.
- XOT ist in der Lage, sowohl einzelne als auch mehrere Lösungen für das Spiel 24 zu generieren. XOT erzielt die beste Leistung in Bezug auf die MultiAcc (Multi-Solution Accuracy).

Ergebnisse Game of 24 (2/2)

Table 3: Performance comparison on Game of 24.

Model	GPT-3.5			GPT-4		
	Acc. [%]	LLM invoked	f_θ invoked	Acc. [%]	LLM invoked	f_θ invoked
IO	6.57	1.00	-	10.22	1.00	-
CoT	2.19	1.00	-	4.38	1.00	-
CoT-SC	2.19	10.00	-	4.38	10.00	-
ToT (b=1)	5.84	22.11	-	34.31	23.50	-
ToT (b=3)	10.22	43.96	-	60.58	39.83	-
GoT (k=1)	2.92	7.00	-	10.95	7.00	-
LLaMA-2-13B	2.19	-	-	2.19	-	-
MCTS	62.77	-	-	62.77	-	-
XoT (w/ 1 r)	**79.56**	**1.39**	**92.15**	**74.45**	**1.38**	**88.20**
XoT (w/ 2 r)	**88.32**	**1.58**	**93.87**	**83.94**	**1.57**	**89.63**
XoT (w/ 3 r)	**90.51**	**1.72**	**95.94**	**85.40**	**1.78**	**92.48**

Ergebnisse 8-Puzzle (1/1)

- Mit GPT-4 erreicht XOT eine **Genauigkeit von 93,28%** mit einer Revision und 95,80% mit drei Revisionen. Die beste **Prompting-Baseline ToT (b=3)**, erreicht nur eine Genauigkeit von **13,45%**.
- XOT benötigt nur etwa **1,6 LLM-Aufrufe für drei Revisionen**, was es zu einer effizienten Lösung macht. Im Vergleich dazu benötigt ToT (b=3) 54,13 LLM-Aufrufe.
- XOT erzielt auch bei der Generierung mehrerer Lösungen die beste Leistung in Bezug auf die MultiAcc. Der Revisionsprozess verbessert die MultiAcc von XOT mit GPT-4 von 51,26% auf 76,33%.

Ergebnisse 8-Puzzle (2/2)

Table 5: Performance comparison on 8-Puzzle.

Model	GPT-3.5			GPT-4		
	Acc. [%]	LLM invoked	f_θ invoked	Acc. [%]	LLM invoked	f_θ invoked
IO	0.00	1.00	-	1.68	1.00	-
CoT	0.00	1.00	-	7.56	1.00	-
CoT-SC	0.84	10.00	-	8.40	10.00	-
ToT (b=1)	5.88	31.76	-	3.36	27.49	-
ToT (b=3)	6.72	55.86	-	13.45	54.13	-
GoT (k=1)	3.36	19.00	-	3.36	19.00	-
LLaMA-2-13B	0.00	-	-	0.00	-	-
MCTS	51.26	-	-	51.26	-	-
XoT (w/ 1 r)	**59.66**	**1.50**	**41.09**	**93.28**	**1.48**	**55.66**
XoT (w/ 2 r)	**59.66**	**1.92**	**42.18**	**94.96**	**1.55**	**58.91**
XoT (w/ 3 r)	**63.03**	**2.29**	**42.60**	**95.80**	**1.61**	**62.22**

Ergebnisse von Pocket Cube (1/2)

- XOT übertrifft alle anderen getesteten Methoden in Bezug auf die Genauigkeit. Mit GPT-4 erreicht XOT eine Genauigkeit von über **77,60%** mit **einer Revision** und über **80 % mit drei Revisionen**. Die beste **Prompting-Baseline**, ToT (b=3), erreicht nur eine Erfolgsquote von **19,57 %**.
- XOT behält eine **hohe Effizienz** bei und benötigt nur etwa 2 LLM-Inferenzaufrufe für sowohl GPT-3.5 als auch GPT-4.
- XOT erreicht mit GPT-4 über 77 % MultiAcc (Multi-Solution Accuracy). Der Revisionsprozess spielt weiterhin eine wichtige Rolle und verbessert die Leistung von XOT mit beiden GPT-Modellen deutlich.

Ergebnisse von Pocket Cube (2/2)

Table 7: Performance comparison on Pocket Cube.

Model	GPT-3.5			GPT-4		
	Acc. [%]	LLM invoked	f_θ invoked	Acc. [%]	LLM invoked	f_θ invoked
IO	1.09	1.00	-	1.09	1.00	-
CoT	0.00	1.00	-	1.09	1.00	-
CoT-SC	0.00	10.00	-	1.09	10.00	-
ToT (b=1)	7.65	16.50	-	11.48	16.39	-
ToT (b=3)	17.49	58.72	-	19.57	56.58	-
GoT (k=1)	1.64	8.93	-	18.03	8.55	-
LLaMA-2-13B	0.00	-	-	0.00	-	-
MCTS	46.44	-	-	46.44	-	-
XoT (w/ 1 r)	**74.32**	**1.55**	**64.63**	**77.60**	**1.54**	**75.51**
XoT (w/ 2 r)	**80.33**	**1.81**	**96.46**	**79.32**	**1.79**	**146.52**
XoT (w/ 3 r)	**84.70**	**2.01**	**103.22**	**83.61**	**2.00**	**84.63**

Everything-of-Thoughts-XoT

- Everything-of-Thoughts-XoT - GitHub
- Errors
  - Can't run examples
- Missing/incorret documentation
- Bad style
  - No .gitignore
  - Empty spaces
  - ...

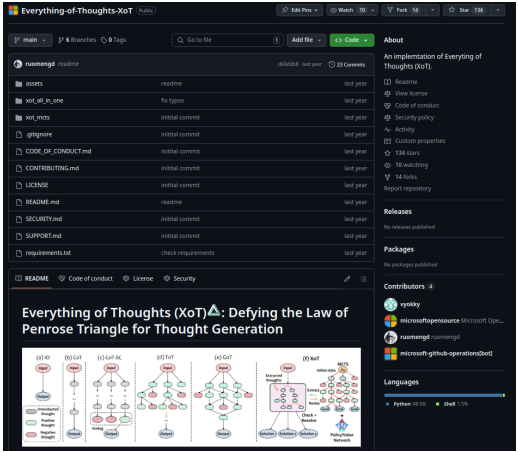

Training

```
python main.py --env game24 --mode train --training_env game24/data/train.csv
    --numMCTSSims 5000 --arenaCompare 100 --numEps 10 --numIters 3
```

- `--env`: Select your desired framework and game.
- `--mode`: train / test.
- `--training_env`: Training data path.
- `--numMCTSSims`: Number of games moves for MCTS to simulate.
- `--arenaCompare`: Number of games to play during arena play to determine if new net will be accepted.
- `--numEps`: Number of complete self-play games to simulate during a new iteration.
- `--numIters:` Number of iteration.

Evaluation

```
python main.py --env game24 --mode test --test_env
    game24/data/test.csv --numMCTSSims 2000 --arenaCompare 137 --multi_sol 0
```

```
INFO TESTING WINS :  5 / 137, THOUGHTS ACC : 3 %, TESTING AVG CALL : 123.8
```

Inference

```
python main.py --config config/cube/single_sol/cube_single_xot_laststep0_revised0
```

```
"To solve the given scrambled 2x2 Pocket Cube, we need to find a sequence
    of moves that will restore the cube to a state where each face has the
    same color. Let's analyze the initial cube state and find the restoration move
...
{
    "r": {
        "r0": {
            "r": 0,
            "revised": false
        },
        "r1": {
            "r": 0,
            "revised": false
        },
```